

Slovenská technická univerzita v Bratislave

Fakulta elektrotechniky a informatiky, Ilkovičova 3, 812 19 Bratislava

Zadanie č.2

3D Gaussian Splatting

Dokumentácia z predmetu: **Počítačové videnie a spracovanie obrazu**

Vypracovali: Maslen Jakub, Kormaníková Dominika
Rok: 2025–2026, 1. ročník Ing.

Obsah

1	Úvod	3
2	Príprava pracovného prostredia	3
2.1	Vytvorenie konfiguračného súboru	3
2.2	Spustenie Docker prostredia	4
3	Referenčný dataset	4
3.1	Príprava dát	4
3.2	Undistortion	4
3.3	Trénovanie modelu	4
3.4	Vizualizácia	5
4	Snímanie vlastnej scény	5
4.1	Spracovanie v nástroji COLMAP	6
4.1.1	Feature Extraction	6
4.1.2	Feature Matching	7
4.1.3	Sparse Reconstruction	7
4.2	Undistortion	8
4.3	Trénovanie modelu	8
4.4	Vizualizácia	9
5	Vyhodnotenie výsledkov	9
5.1	Porovnanie PSNR	9
5.2	Vizuálne porovnanie	9
5.3	Diskusia	9
6	Záver	10

1 Úvod

Cieľom zadania bolo oboznámiť sa s modernou metódou rekonštrukcie 3D scény pomocou **3D Gaussian Splatting**. Úlohou bolo prejsť celý proces spracovania dát od fotografií až po vizualizáciu výslednej scény - interaktívny 3D viewer.

Postup bol realizovaný najprv na referenčnom datasete a následne na vlastnoručnej scéne nasnímanej kamerou alebo v našom prípade sme použili mobilný telefón.


2 Príprava pracovného prostredia

Práca na zadání bola realizovaná na školskom počítači v laboratóriu. Pre zadanie bol vytvorený priečinok určený pre projekt, ktorý obsahoval zdrojové súbory, datasety a výsledné modely.

Do pracovného priečinka bol následne naklonovaný repozitár poskytnutý vyučujúcim pomocou systému Git:

```
git clone https://github.com/michKovac/PVSO-gaussian-splatting-assignment.git
```

Repozitár obsahoval pripravené skripty, Docker konfiguráciu a návod na postup celého zadania.



Obr. 1: Použité pracovné prostredie

2.1 Vytvorenie konfiguračného súboru

Pred spustením projektu bolo potrebné vytvoriť konfiguračný súbor **.env**, ktorý obsahoval cesty k datasetom a pracovným priečinkom.

```
DATA_PATH=/home/d618/PVSO_Maslen_Kormanikova/our_dataset  
OUTPUT_PATH=/home/d618/PVSO_Maslen_Kormanikova/Output_real
```

Tento súbor zabezpečil správne prepojenie medzi lokálnymi adresármi a prostredím v Docker kontajneri.

2.2 Spustenie Docker prostredia

Po nastavení konfiguračného súboru bol spustený Docker kontajner pomocou skriptu:

```
./run.sh
```


Docker prostredie obsahovalo všetky potrebné knižnice a nástroje, ako napríklad COLMAP, Python a ďalšie závislosti, ktoré sú potrebné pre spracovanie dát a tréning modelu.

3 Referenčný dataset

Ako referenčný dataset bol použitý dataset **flowers**, konkrétne podpriechinok **images_4**.

Použité boli iba vstupné fotografie bez predpočítaných dát. Na tejto úlohe sme pochopili celý pracovný postup a overili celkovú funkčnosť prostredia bez problémov spojených so snímaním scény.

Počet fotografií v datasete: **173**.



Obr. 2: Použitý referenčný dataset

3.1 Príprava dát

Referenčný dataset bol použitý bez potreby vykonania krokov Feature Extraction, Feature Matching a Sparse Reconstruction v nástroji COLMAP.

Dataset obsahoval pripravené údaje, ktoré umožnili priamo pokračovať v ďalších krokoch spracovania.

3.2 Undistortion

Fotografie boli upravené pomocou skriptu:

```
python3 convert.py -s data/flowers --skip_matching
```

Tento krok slúži na odstránenie geometrického skreslenia a prípravu dát pre tréning modelu.

3.3 Tréning modelu

Model bol tréňovaný pomocou skriptu:

```
python3 train.py -s data/360_extra_scenes_flowers -r 8 --densify_until_iter 5000
```

Počas tréovania boli sledované hodnoty metriky PSNR, ktorá vyjadruje kvalitu rekonštrukcie scény.

```
root@d618-System-Product-Name:/opt/gaussian-splatting# cd data
root@d618-System-Product-Name:/opt/gaussian-splatting/data# ls
360_extra_scenes
root@d618-System-Product-Name:/opt/gaussian-splatting/data# cd 360_extra_scenes/
root@d618-System-Product-Name:/opt/gaussian-splatting/data/360_extra_scenes# ls
flowers treehill
root@d618-System-Product-Name:/opt/gaussian-splatting/data/360_extra_scenes# cd
flowers
root@d618-System-Product-Name:/opt/gaussian-splatting/data/360_extra_scenes/flowers# cd ..
root@d618-System-Product-Name:/opt/gaussian-splatting/data# cd ..
root@d618-System-Product-Name:/opt/gaussian-splatting# python3 train.py -s data/
360_extra_scenes/flowers -r 8 --densify_until_iter 5000
Optimizing
Output folder: ./output/f68a8a92-f [23/04 18:02:21]
Tensorboard not available: not logging progress [23/04 18:02:21]
Reading camera 173/173 [23/04 18:02:21]
Loading Training Cameras [23/04 18:02:21]
Loading Test Cameras [23/04 18:02:47]
Number of points at initialisation : 38347 [23/04 18:02:47]
Training progress: 23% | 7000/30000 [05:07<23:28, 16.33it/s, Loss=0.0707035, 0]
[ITER 7000] Evaluating train: L1 0.036919066682457924 PSNR 24.660219192504883 [2
3/04 18:07:55]
[ITER 7000] Saving Gaussians [23/04 18:07:55]
Training progress: 23% | 7030/30000 [05:16<1:01:51, 6.19it/s, Loss=0.0767251,
```

(a) 7000 iterácií

```
root@d618-System-Product-Name:/opt/gaussian-splatting# cd ..
root@d618-System-Product-Name:/opt/gaussian-splatting# python3 train.py -s data/
360_extra_scenes/flowers -r 8 --densify_until_iter 5000
Optimizing
Output folder: ./output/f68a8a92-f [23/04 18:02:21]
Tensorboard not available: not logging progress [23/04 18:02:21]
Reading camera 173/173 [23/04 18:02:21]
Loading Training Cameras [23/04 18:02:21]
Loading Test Cameras [23/04 18:02:47]
Number of points at initialisation : 38347 [23/04 18:02:47]
Training progress: 23% | 7000/30000 [05:07<23:28, 16.33it/s, Loss=0.0707035, 0]
[ITER 7000] Evaluating train: L1 0.036919066682457924 PSNR 24.660219192504883 [2
3/04 18:07:55]
[ITER 7000] Saving Gaussians [23/04 18:07:55]
Training progress: 100% | 30000/30000 [28:12<00:00, 17.72it/s, Loss=0.0687089,
[ITER 30000] Evaluating train: L1 0.02834809608757496 PSNR 26.77356414794922 [23
/04 18:31:00]
[ITER 30000] Saving Gaussians [23/04 18:31:00]
Training complete. [23/04 18:31:07]
root@d618-System-Product-Name:/opt/gaussian-splatting#
```


(b) 30000 iterácií

Obr. 3: Porovnanie priebehu tréovania referenčnej scény


3.4 Vizualizácia

Po dokončení tréovania bola výsledná scéna zobrazená pomocou vieweru:

`SIBR_gaussianViewer_app -m output/<uuid>`



(a) Pohľad 1



(b) Pohľad 2

Obr. 4: Porovnanie referenčnej scény z rôznych uhlov

4 Snímanie vlastnej scény

Najprv bola vytvorená vlastná scéna s objektom **hrnček na stole**. Táto scéna sa však nepodarila správne rekonštruovať.

Hlavným problémom pri rekonštrukcii prvej scény s hrnčekom bolo nedostatočné pokrytie objektu zo všetkých uhlov, v dôsledku čoho neboli niektoré časti objektu zachytené na snímkach. Výsledkom bola neúplná rekonštrukcia scény, ktorá sa prejavila chýbajúcimi časťami modelu a nemožnosťou plynule rotovať okolo objektu. Ďalším problémom boli odrazy na povrchu hrnčeka, ktoré negatívne ovplyvnili detekciu príznakov počas spracovania.

Z tohto dôvodu bola vytvorená nová scéna s objektom **Rubikova kocka na stole**.

Táto scéna obsahovala dostatočný počet fotografií a objekt mal vhodnú textúru pre rekonštrukciu.

Počet fotografií vlastnej scény: 171

4.1 Spracovanie v nástroji COLMAP

Pre vlastnú scénu bolo potrebné vykonať rekonštrukciu pomocou nástroja COLMAP.

Najprv bol spustený grafický nástroj:


colmap gui

V prostredí COLMAP boli postupne vykonané nasledujúce kroky.

4.1.1 Feature Extraction

V tomto kroku boli z fotografií extrahované výrazné príznaky pomocou modelu kamery **SIMPLE_PINHOLE**.

Tento krok identifikuje charakteristické body na jednotlivých snímkach, ktoré budú použité pri rekonštrukcii scény.




Obr. 5: Feature extraction vlastnej scény

4.1.2 Feature Matching

Po extrakcii príznakov nasledovalo ich vzájomné párovanie pomocou metódy **Exhaustive Matching**.

Tento krok slúži na nájdenie zodpovedajúcich bodov medzi jednotlivými fotografiami.




Obr. 6: Feature matching vlastnej scény

4.1.3 Sparse Reconstruction

Na základe spárovaných príznakov bola vytvorená riedka rekonštrukcia scény.

V tomto kroku sa vypočítava poloha kamier a 3D súradnice bodov v priestore.



Obr. 7: Sparse rekonštrukcia vlastnej scény

4.2 Undistortion

Po dokončení rekonštrukcie sme už pokračovali rovnakým postupom ako pri referenčnom datasete. Fotografie boli upravené pomocou skriptu:

```
python3 convert.py -s data/moja_scena --skip_matching
```


Tento krok slúži na odstránenie geometrického skreslenia a prípravu dát pre tréningovanie modelu.

4.3 Trénovanie modelu

Model vlastnej scény bol tréňovaný pomocou skriptu:

```
python3 train.py -s data/moja_scena --data_device cpu
```

Počas tréningovania boli sledované hodnoty metriky PSNR.




(a) 7000 iterácií

(b) 30000 iterácií


Obr. 8: Porovnanie priebehu tréningovania vlastnej scény

4.4 Vizualizácia

Po dokončení tréningu bola výsledná scéna zobrazená pomocou vieweru.



(a) Pohľad 1



(b) Pohľad 2

Obr. 9: Porovnanie vlastnej scény z rôznych uhlov

5 Vyhodnotenie výsledkov

5.1 Porovnanie PSNR

Scéna	PSNR (7000 iterácií)	PSNR (30000 iterácií)
Referenčný dataset (flowers)	24.66021	26.77356
Vlastná scéna (Rubikova kocka)	35.32320	38.42031

Tabuľka 1: Porovnanie PSNR hodnôt pre referenčný dataset a vlastnú scénu

5.2 Vizuálne porovnanie

Porovnanie renderov z rovnakých uhlov pohľadu.



Obr. 10: Porovnanie renderov

5.3 Diskusia

Kvalitu výslednej rekonštrukcie ovplyvnilo viacero faktorov:

- Počet fotografií
- Pokrytie objektu zo všetkých uhlov
- Textúra objektu
- Osvetlenie

Prvá scéna s hrnčekom nebola úspešná kvôli nedostatočnému pokrytiu objektu a prítomnosti odrazov na jeho povrchu.

Druhá scéna s Rubikovou kockou bola úspešná, pretože objekt mal výraznú textúru a bol dostatočne nafotený z rôznych uhlov.

6 Záver

V rámci zadania bol úspešne realizovaný kompletný proces rekonštrukcie 3D scény pomocou metódy 3D Gaussian Splatting.

Experiment ukázal, že kvalita rekonštrukcie výrazne závisí od správneho pokrytia objektu, počtu fotografií a vhodného výberu objektu.

Pre lepšie výsledky by bolo vhodné:

- Použiť ešte väčší počet fotografií
- Zabezpečiť rovnomerné osvetlenie
- Dôsledne pokryť objekt zo všetkých uhlov