

Slovenská technická univerzita v Bratislave

Fakulta elektrotechniky a informatiky, Ilkovičova 3, 812 19 Bratislava

Zadanie č.2

3D Gaussian Splatting

Dokumentácia z predmetu: **Počítačové videnie a spracovanie obrazu**

Vypracovali: Maslen Jakub, Kormaníková Dominika
Rok: 2025–2026, 1. ročník Ing.

Obsah

1	Úvod	3
2	Príprava pracovného prostredia	3
2.1	Vytvorenie konfiguračného súboru	3
2.2	Spustenie Docker prostredia	4
3	Referenčný dataset	4
3.1	Príprava dát	4
3.2	Undistortion	4
3.3	Trénovanie modelu	4
3.4	Vizualizácia	5
4	Snímanie vlastnej scény	5
4.1	Spracovanie v nástroji COLMAP	6
4.1.1	Feature Extraction	6
4.1.2	Feature Matching	7
4.1.3	Sparse Reconstruction	8
4.2	Undistortion	9
4.3	Trénovanie modelu	9
4.4	Vizualizácia	9
5	Vyhodnotenie výsledkov	10
5.1	Porovnanie PSNR	10
5.2	Vizuálne porovnanie	10
5.3	Diskusia	10
6	Záver	10

1 Úvod

Cieľom zadania bolo oboznámiť sa s modernou metódou rekonštrukcie 3D scény pomocou **3D Gaussian Splatting**. Úlohou bolo prejsť celý proces spracovania dát od fotografií až po vizualizáciu výslednej scény - interaktívny 3D viewer.

Postup bol realizovaný najprv na referenčnom datasete a následne na vlastnoručnej scéne nasnímanej kamerou alebo v našom prípade sme použili mobilný telefón.


2 Príprava pracovného prostredia

Práca na zadání bola realizovaná na školskom počítači v laboratóriu. Pre zadanie bol vytvorený priečinok určený pre projekt, ktorý obsahoval zdrojové súbory, datasety a výsledné modely.

Do pracovného priečinka bol následne naklonovaný repozitár poskytnutý vyučujúcim pomocou systému Git:

```
git clone https://github.com/michKovac/PVSO-gaussian-splatting-assignment.git
```

Repozitár obsahoval pripravené skripty, Docker konfiguráciu a návod na postup celého zadania.



Obr. 1: Použité pracovné prostredie

2.1 Vytvorenie konfiguračného súboru

Pred spustením projektu bolo potrebné vytvoriť konfiguračný súbor **.env**, ktorý obsahoval cesty k datasetom a pracovným priečinkom.

```
DATA_PATH=/home/d618/PVSO_Maslen_Kormanikova/our_dataset  
OUTPUT_PATH=/home/d618/PVSO_Maslen_Kormanikova/Output_real
```

Tento súbor zabezpečil správne prepojenie medzi lokálnymi adresármi a prostredím v Docker kontajneri.

2.2 Spustenie Docker prostredia

Po nastavení konfiguračného súboru bol spustený Docker kontajner pomocou skriptu:

```
./run.sh
```


Docker prostredie obsahovalo všetky potrebné knižnice a nástroje, ako napríklad COLMAP, Python a ďalšie závislosti, ktoré sú potrebné pre spracovanie dát a tréning modelu.

3 Referenčný dataset

Ako referenčný dataset bol použitý dataset **flowers**, konkrétne podpriechinok **images_4**.

Použité boli iba vstupné fotografie bez predpočítaných dát. Na tejto úlohe sme pochopili celý pracovný postup a overili celkovú funkčnosť prostredia bez problémov spojených so snímaním scény.

Počet fotografií v datasete: **173**.



Obr. 2: Použitý referenčný dataset

3.1 Príprava dát

Referenčný dataset bol použitý bez potreby vykonania krokov Feature Extraction, Feature Matching a Sparse Reconstruction v nástroji COLMAP GUI. Dataset obsahoval pripravené fotografie, s ktorými sme už ďalej priamo pracovali.

3.2 Undistortion

Fotografie boli spracované pomocou skriptu:

```
python3 convert.py -s data/flowers --skip_matching
```

Tento krok slúži na prípravu vstupných dát pre tréning modelu. Skript vykoná úpravu fotografií tak, aby boli vhodné pre následné spracovanie. Pri referenčnom datasete bol použitý parameter **-skip_matching**, pretože dataset už obsahoval predpočítané informácie o zodpovedajúcich bodoch medzi obrázkami. Tento krok tak zabezpečil rýchlejšiu prípravu dát bez potreby opätovného výpočtu feature matching.

3.3 Tréning modelu

Model bol tréňovaný pomocou skriptu:

```
python3 train.py -s data/360_extra_scenes_flowers -r 8 --densify_until_iter 5000
```


Počas trénovania boli sledované hodnoty metriky PSNR, ktorá vyjadruje kvalitu rekonštrukcie scény. Vyššia hodnota PSNR znamená presnejšiu rekonštrukciu obrazu.

```
root@d618-System-Product-Name:/opt/gaussian-splatting# cd data
root@d618-System-Product-Name:/opt/gaussian-splatting/data# ls
360_extra_scenes
root@d618-System-Product-Name:/opt/gaussian-splatting/data# cd 360_extra_scenes/
root@d618-System-Product-Name:/opt/gaussian-splatting/data/360_extra_scenes# ls
flowers_trainkill
root@d618-System-Product-Name:/opt/gaussian-splatting/data/360_extra_scenes# cd
..
root@d618-System-Product-Name:/opt/gaussian-splatting/data# cd ..
root@d618-System-Product-Name:/opt/gaussian-splatting# python3 train.py -s data/
360_extra_scenes/flowers -r 0 --densify_until_iter 5000
Optimizing
Output folder: ./output/f68a8a92-f [23/04 18:02:21]
Tensorboard not available: not logging progress [23/04 18:02:21]
Reading camera 173/173 [23/04 18:02:21]
Loading Training Cameras [23/04 18:02:21]
Loading Test Cameras [23/04 18:02:47]
Number of points at initialisation: 38347 [23/04 18:02:47]
Training progress: 23% [23/04 18:02:47] | 7000/30000 [05:07<23:28, 16.33it/s, Loss=0.0707035, 0]
[ITER 7000] Evaluating train: L1 0.036919066082457924 PSNR 24.660219192504883 [2
3/04 18:07:55]
[ITER 7000] Saving Gaussians [23/04 18:07:55]
Training progress: 23% [23/04 18:07:55] | 7000/30000 [05:16<1:01:51, 6.19it/s, Loss=0.0767251,
```

(a) 7000 iterácií

```
root@d618-System-Product-Name:/opt/gaussian-splatting# cd ..
root@d618-System-Product-Name:/opt/gaussian-splatting# python3 train.py -s data/
360_extra_scenes/flowers -r 0 --densify_until_iter 5000
Optimizing
Output folder: ./output/f68a8a92-f [23/04 18:02:21]
Tensorboard not available: not logging progress [23/04 18:02:21]
Reading camera 173/173 [23/04 18:02:21]
Loading Training Cameras [23/04 18:02:21]
Loading Test Cameras [23/04 18:02:47]
Number of points at initialisation: 38347 [23/04 18:02:47]
Training progress: 23% [23/04 18:02:47] | 7000/30000 [05:07<23:28, 16.33it/s, Loss=0.0707035, 0]
[ITER 7000] Evaluating train: L1 0.036919066082457924 PSNR 24.660219192504883 [2
3/04 18:07:55]
[ITER 7000] Saving Gaussians [23/04 18:07:55]
Training progress: 100% [23/04 18:07:55] | 30000/30000 [28:12<00:00, 17.72it/s, Loss=0.0687089,
0/0 18:31:00]
[ITER 30000] Evaluating train: L1 0.02834809608757496 PSNR 26.77356414794922 [23
/04 18:31:00]
[ITER 30000] Saving Gaussians [23/04 18:31:00]
Training complete. [23/04 18:31:07]
root@d618-System-Product-Name:/opt/gaussian-splatting#
```


(b) 30000 iterácií

Obr. 3: Porovnanie priebehu trénovania referenčnej scény


3.4 Vizualizácia

Po dokončení trénovania bola výsledná scéna zobrazená pomocou vieweru:

`SIBR_gaussianViewer_app -m output/<uuid>`



(a) Pohľad 1



(b) Pohľad 2

Obr. 4: Porovnanie referenčnej scény z rôznych uhlov

4 Snímanie vlastnej scény

Najprv bola vytvorená vlastná scéna s **hrnčekom na stole v učebni**. Táto scéna sa však nepodarila správne rekonštruovať.

Hlavným problémom pri rekonštrukcii prvej scény s hrnčekom bolo, že bol jednej farby a nemal žiadne príznaky v dôsledku čoho neboli niektoré časti objektu rozoznateľné. Výsledkom bola neúplná rekonštrukcia scény, ktorá sa prejavila chýbajúcimi časťami modelu a nemožnosťou plynule rotovať okolo objektu. Ďalším problémom mohli byť odrazy na povrchu hrnčeka, ktoré tiež negatívne ovplyvnili detekciu príznakov počas spracovania.

Z tohto dôvodu bola vytvorená nová scéna s **rubikovou kockou na stole v učebni**.

Táto scéna obsahovala už väčší počet fotografií zo všetkých uhlov a objekt mal vhodnú textúru pre rekonštrukciu.

Počet fotografií vlastnej scény: 171

4.1 Spracovanie v nástroji COLMAP

Pre vlastnú scénu bolo potrebné vykonať rekonštrukciu pomocou nástroja COLMAP GUI.

Najprv bol spustený grafický nástroj:


```
colmap gui
```

V prostredí COLMAP boli postupne vykonané nasledujúce kroky.

4.1.1 Feature Extraction

V tomto kroku boli z fotografií extrahované výrazné príznaky pomocou modelu kamery **SIMPLE_PINHOLE**.

Tento krok identifikuje charakteristické body na jednotlivých snímkach, ktoré budú použité pri rekonštrukcii scény.




Obr. 5: Feature extraction vlastnej scény

4.1.2 Feature Matching

Po extrakcii príznačov nasledovalo ich vzájomné párovanie pomocou metódy **Exhaustive Matching**.


Tento krok slúži na nájdenie zodpovedajúcich bodov medzi jednotlivými fotografiami.



Obr. 6: Feature matching vlastnej scény

4.1.3 Sparse Reconstruction

Na základe spárovaných príznakov bola vytvorená rekonštrukcia scény. V tomto kroku sa vypočítava poloha kamier a 3D súradnice bodov v priestore.



Obr. 7: Sparse rekonštrukcia vlastnej scény

4.2 Undistortion

Po dokončení rekonštrukcie sme už pokračovali rovnakým postupom ako pri referenčnom datasete. Fotografie boli upravené pomocou skriptu:

```
python3 convert.py -s data/moja_scena --skip_matching
```

Tento krok slúži na odstránenie geometrického skreslenia a prípravu dát pre trénovanie modelu.

4.3 Trénovanie modelu

Model vlastnej scény bol trénovaný pomocou skriptu:

```
python3 train.py -s data/moja_scena --data_device cpu
```

Počas trénovania boli sledované hodnoty metriky PSNR.

```
root@6d18-System-Product-Name: /opt/gaussian-splatting
root@6d18-System-Product-Name: /opt/gaussian-splatting
00423 15:50:04.184080 3609 undistortion.cc:210] undistorting image [158/171]
00423 15:50:04.184093 3609 undistortion.cc:210] undistorting image [159/171]
00423 15:50:04.190181 3609 undistortion.cc:210] undistorting image [160/171]
00423 15:50:04.190190 3609 undistortion.cc:210] undistorting image [161/171]
00423 15:50:04.190194 3609 undistortion.cc:210] undistorting image [162/171]
00423 15:50:04.190198 3609 undistortion.cc:210] undistorting image [163/171]
00423 15:50:04.190204 3609 undistortion.cc:210] undistorting image [164/171]
00423 15:50:04.190208 3609 undistortion.cc:210] undistorting image [165/171]
00423 15:50:04.190218 3609 undistortion.cc:210] undistorting image [166/171]
00423 15:50:04.190224 3609 undistortion.cc:210] undistorting image [167/171]
00423 15:50:04.190230 3609 undistortion.cc:210] undistorting image [168/171]
00423 15:50:04.190236 3609 undistortion.cc:210] undistorting image [169/171]
00423 15:50:04.190242 3609 undistortion.cc:210] undistorting image [170/171]
00423 15:50:04.190247 3609 undistortion.cc:210] undistorting image [171/171]
00423 15:50:04.190251 3609 undistortion.cc:223] Writing reconstruction...
00423 15:50:04.212249 3609 undistortion.cc:223] Writing configuration...
00423 15:50:04.220249 3609 timer.cc:91] elapsed time: 0.065 [minutes]
Done.
root@6d18-System-Product-Name: /opt/gaussian-splatting python3 train.py -s data/moja_scena/ --data_device cpu
Outlining
Output folder: /output/004230000 [23/04 15:50:31]
Tensorboard not available: not logging progress [23/04 15:50:31]
Loading camera 171/171 [23/04 15:50:31]
Converting points3d.bvh to .ply, will happen only the first time you open the scene. [23/04 15:50:31]
Loading Training Camera [23/04 15:50:31]
[ INFO ] Resampled white large input images (1.0x pixels width), rescaling to 1.0x.
If this is not desired, please explicitly specify --resolution/r as 1 [23/04 15:50:31]
Loading test camera [23/04 15:50:31]
Number of points at initialization: 9066 [23/04 15:50:31]
Training progress: 23% | 7000/30000 [16:15:10:02, 6.1811/s, Loss=0.0226430, Depth Loss=0.0000000]
[ITER 7000] Evaluating train: L1 0.01891939476964 PSNR 35.32203751769866 [23/04 16:07:15]
[ITER 7000] Saving Gaussians [23/04 16:07:15]
Training progress: 23% | 1000/30000 [16:12:37:45, 9.7011/s, Loss=0.0163555, Depth Loss=0.0000000]
```

(a) 7000 iterácií


```
root@6d18-System-Product-Name: /opt/gaussian-splatting
root@6d18-System-Product-Name: /opt/gaussian-splatting
00423 15:50:04.190228 3609 undistortion.cc:210] undistorting image [165/171]
00423 15:50:04.190233 3609 undistortion.cc:210] undistorting image [166/171]
00423 15:50:04.190238 3609 undistortion.cc:210] undistorting image [167/171]
00423 15:50:04.190242 3609 undistortion.cc:210] undistorting image [168/171]
00423 15:50:04.190247 3609 undistortion.cc:210] undistorting image [169/171]
00423 15:50:04.190251 3609 undistortion.cc:210] undistorting image [170/171]
00423 15:50:04.190257 3609 undistortion.cc:210] undistorting image [171/171]
00423 15:50:04.190261 3609 undistortion.cc:223] Writing reconstruction...
00423 15:50:04.212249 3609 undistortion.cc:223] Writing configuration...
00423 15:50:04.220249 3609 timer.cc:91] elapsed time: 0.065 [minutes]
Done.
root@6d18-System-Product-Name: /opt/gaussian-splatting python3 train.py -s data/moja_scena/ --data_device cpu
Outlining
Output folder: /output/004230000 [23/04 15:50:31]
Tensorboard not available: not logging progress [23/04 15:50:31]
Loading camera 171/171 [23/04 15:50:31]
Converting points3d.bvh to .ply, will happen only the first time you open the scene. [23/04 15:50:31]
[ INFO ] Resampled white large input images (1.0x pixels width), rescaling to 1.0x.
If this is not desired, please explicitly specify --resolution/r as 1 [23/04 15:50:31]
Loading Training Camera [23/04 15:50:31]
Number of points at initialization: 9066 [23/04 15:50:31]
Training progress: 23% | 7000/30000 [16:15:10:02, 6.1811/s, Loss=0.0226430, Depth Loss=0.0000000]
[ITER 7000] Evaluating train: L1 0.01891939476964 PSNR 35.32203751769866 [23/04 16:07:15]
[ITER 7000] Saving Gaussians [23/04 16:07:15]
Training progress: 23% | 1000/30000 [16:12:37:45, 9.7011/s, Loss=0.0163555, Depth Loss=0.0000000]
[ITER 30000] Evaluating train: L1 0.008541380000306708 PSNR 38.42031097421804 [23/04 17:13:01]
Training complete. [23/04 17:13:01]
root@6d18-System-Product-Name: /opt/gaussian-splatting
```

(b) 30000 iterácií


Obr. 8: Porovnanie priebehu trénovania vlastnej scény

4.4 Vizualizácia

Po dokončení trénovania bola výsledná scéna zobrazená pomocou vieweru.



(a) Pohľad 1



(b) Pohľad 2

Obr. 9: Porovnanie vlastnej scény z rôznych uhlov

5 Vyhodnotenie výsledkov


5.1 Porovnanie PSNR

Scéna	PSNR (7000 iterácií)	PSNR (30000 iterácií)
Referenčný dataset - flowers	24.66021	26.77356
Vlastná scéna - rubikova kocka	35.32320	38.42031

Tabuľka 1: Porovnanie PSNR hodnôt pre referenčný dataset a vlastnú scénu

5.2 Vizuálne porovnanie

Porovnanie renderov z rovnakých uhlov pohľadu.



Obr. 10: Porovnanie renderov z rovnakých uhlov pohľadu

5.3 Diskusia

Kvalitu výslednej rekonštrukcie ovplyvnilo viacero faktorov:

- Počet fotografií
- Pokrytie objektu zo všetkých uhlov
- Textúra objektu - odrazy
- Osvetlenie pomocou umelého svetla

Prvá scéna s hrnčekom nebola úspešná kvôli nedostatočnému pokrytiu objektu a prítomnosti odrazov na jeho povrchu. Druhá scéna s Rubikovou kockou bola úspešná, pretože objekt mal výraznú textúru a bol dostatočne nafotený z rôznych uhlov.

6 Záver

V rámci zadania bol úspešne realizovaný kompletný proces rekonštrukcie 3D scény pomocou metódy 3D Gaussian Splatting.

Experiment ukázal, že kvalita rekonštrukcie výrazne závisí od správneho pokrytia objektu, počtu fotografií, vhodného výberu objektu a rovnomerného osvetlenia objektu.

Pre lepšie výsledky by bolo vhodné:

- Použiť ešte väčší počet fotografií
- Zabezpečiť prírodné osvetlenie v exteriérových podmienkach
- Dôsledne pokryť fotografie objektu zo všetkých uhlov